

MBA EM **ENGENHARIA DE SOFTWARE**

Engenharia de Dados I

Guilherme Lima


MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98





O que é engenharia de dados?




Google



Google Search

I'm Feeling Lucky

Engenharia de dados




A engenharia de dados é a área responsável pelo desenvolvimento e manutenção de sistemas que coletam, organizam, e processam dados.


Engenharia de dados

Construir a base para a ciência de dados





Ciclo de vida dos *dados*






ETL - *Extração, Transformação, Carregamento*



Extração

Coleta dados de
diferentes fontes



Transformação


Dos dados para atender às
necessidades



Carregamento

Carregamento dos
dados

Annual Size of the Global Datasphere



Source: Data Age 2025, sponsored by Seagate with data from IDC Global DataSphere, Nov 2018


Engenharia de dados tem tudo a ver com
movimentação, manipulação e gerenciamento de
dados.

Desafio

A Aquisição: Digital encontra o Físico

Tênis Direto compra Rede Pé Firme

O e-commerce nativo digital **Tênis Direto** expande sua operação adquirindo a **Rede Pé Firme**, uma rede tradicional com 8 unidades físicas no Brasil.



A Aquisição: Digital encontra o Físico

Esta união representa o encontro de dois mundos com maturidades digitais e estruturas de dados completamente opostas.



O Desafio: Omnichannel



Ship from Store

O objetivo é permitir que um pedido feito no site seja atendido pela loja física mais próxima com estoque disponível.

Meta: Redução de frete, tempo de entrega e otimização do giro de estoque físico através do canal digital.

| Conflito de Ecossistemas

Aspecto	Tênis Direto (Digital)	Rede Pé Firme (Física)
Formato	JSON (API-ready)	CSV (latin-1, ";" separator)
Qualidade	Limpo, padronizado	Sujo: espaços e duplicatas
Identificador	SKU slug (nike-air-max-90)	EAN-13 (com falhas)
Padrão	Nomes padronizados	Caixa alta, abreviações

Extract (E): A Diversidade de Origens



JSON

Estrutura hierárquica, flexível e nativa para a web. Utilizada pelo e-commerce para agilidade em APIs.



CSV Legacy

Codificação Latin-1 e separadores não convencionais. Requer tratamento de caracteres especiais (acentuação).

| Transform (T): Limpeza de Dados

-  **Trim & Clean:** Remoção de espaços extras e caracteres invisíveis comuns no sistema legado da PéFirme.
-  **Case Normalization:** Conversão de "CAIXA ALTA E ABREV." para o padrão amigável do e-commerce.
-  **Deduplicação:** Identificação de registros duplicados que geram "estoque fantasma".
-  **Encoding:** Transcrição de Latin-1 para UTF-8 para garantir compatibilidade global.

| O Desafio dos Identificadores

13

Dígitos EAN (com falhas)

Maapeamento SKU vs. EAN

Enquanto o digital usa Slugs legíveis (nike-air-max-90-branco-42), o físico usa códigos de barras EAN-13 que muitas vezes estão incompletos ou errados.

A Solução ETL: Criar uma tabela de *Cross-Reference* (De-Para) para unificar o catálogo.

| O Ciclo de Vida da Integração

Extração

Consumo de APIs JSON e ingestão de arquivos CSV legacy.



Transformação

Limpeza, Deduplicação e Mapeamento de SKUs.



Carga (Load)


Povoamento do Data Warehouse central para o Omnichannel.



Resultado: Omnichannel Fluido

Com o pipeline ETL estabilizado, a Tênis Direto agora visualiza o estoque das 8 lojas físicas como se fossem centros de distribuição próprios.

Experiência do cliente elevada: Compre online, receba da loja ao lado em 2 horas.



Obrigado!

Guilherme Lima | [linkedin](#)

MBAUSP
ESALQ