

MBA EM **ENGENHARIA DE SOFTWARE**

Engenharia de Dados II

Prof. Guilherme Lima

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Onde estamos?

Recapitulando a criação dos nossos arquivos

Parquet

Onde estamos?

Recapitulando a criação dos nossos arquivos

Parquet



Armazenamento Colunar

Ideal para análise de grandes volumes.



Alta Compressão

Reduz custos de armazenamento em nuvem.



Esquema Embutido

Preserva tipos de dados e metadados.

Row-based Storage

Name	Age	City
John	25	NYC
Jane	30	SF

Columnar Storage (Parquet)

ID	Name	Age
1	John	25
2	Jane	30

Benefits of Columnar Storage

Better Compression

Efficient Analytical Queries



E agora?

Vamos pensar na arquitetura dos dados



Após o ETL e a geração dos arquivos Parquet, temos três opções principais de arquitetura de dados:

- Data Lake
- Data Warehouse
- Lakehouse

O que é um Data Lake?

O Repositório Central

Um Data Lake é um repositório centralizado que permite **armazenar** todos os seus **dados estruturados e não estruturados** em qualquer escala.

É o "**destino natural**" para os arquivos Parquet que criamos, **geralmente hospedado em serviços** como AWS S3, Azure Data Lake Storage ou Google Cloud Storage.



Vantagens do Data Lake

- ✓ Schema-on-Read: Você não precisa definir a estrutura antes de salvar o dado (flexibilidade total).
- ✓ Baixo Custo: Armazenamento de objetos é extremamente barato comparado a bancos relacionais.
- ✓ Diversidade: Suporta vídeos, logs, JSONs, Parquet e imagens no mesmo lugar.
- ✓ Escalabilidade: Cresce horizontalmente de forma quase infinita.

Três opções principais de arquitetura de dados:

- ~~Data Lake~~

- Data Warehouse

- Lakehouse

O que é um Data Warehouse?

Um Data Warehouse (DW) é um sistema de banco de dados otimizado para análise de dados e Business Intelligence.

Diferente do Lake, o DW exige Schema-on-Write: o dado deve estar limpo e estruturado antes de entrar.

É onde o SQL reina absoluto para relatórios.

O Império do Data Warehouse



Performance: Altíssima **velocidade** para consultas SQL complexas.



Governança: Controle rígido de **quem acessa** o quê.



Qualidade: **Apenas dados validados e limpos** residem aqui.



Histórico: Excelente para **análise de tendências** ao longo do tempo.

Comparativo

Característica	Data Lake	Data Warehouse
Dados	Brutos, semi e estruturados	Altamente estruturados
Esquema	Schema-on-Read (Flexível)	Schema-on-Write (Rígido)
Custo	Baixo	Moderado a Alto
Usuários	Cientistas e Engenheiros de Dados	Analistas de BI e Negócio

Pergunta

Qual melhor se encaixa para nosso desafio?

DL

DW




Três opções principais de arquitetura de dados:

- ~~*Data Lake*~~
- ~~Data Warehouse~~
- **Lakehouse**

Conheça o Data Lakehouse

O Data Lakehouse é uma arquitetura moderna que combina a **flexibilidade** e o **custo** do Data Lake com a **performance** e **governança** do Data Warehouse.

Permite que você execute **SQL** diretamente sobre seus **arquivos Parquet** com a mesma segurança de um banco de dados tradicional.



O Melhor de Dois Mundos



Suporte a ACID

Garante que as operações de escrita e leitura sejam seguras, evitando corrupção de dados em processamentos paralelos.



Indexação e Metadados

Camadas de metadados inteligentes permitem localizar dados rapidamente, acelerando consultas de BI.



Fonte Única da Verdade

Elimina a necessidade de mover dados entre Lake e Warehouse, reduzindo a complexidade e o custo.

| Eficiência do Parquet no Lakehouse

10x

Mais rápido que CSV em buscas

80%

Menos espaço em disco

Arquitetura Medalhão

O padrão de ouro para organizar seus arquivos Parquet

As Três Camadas do Lakehouse



Bronze (Raw)

Dados brutos vindos das fontes após ingestão, preservando o máximo possível do formato original.



Silver (Cleaned)

Dados limpos, filtrados e enriquecidos, tornando-se confiáveis para análise



Gold (Curated)


Dados agregados e prontos para consumo. Estruturas otimizadas para dashboards e modelos de Machine Learning.

[Link de exemplo das camadas](#)

Comparativo de Desempenho SQL



Evolução do Mercado de Dados



Migração acelerada para arquiteturas unificadas.

Composição do Pipeline de Dados



- 60% Ingestão e ETL (Parquet)
- 25% Limpeza e Governança (Silver)
- 15% Visualização e BI (Gold)

Ferramentas do Ecossistema



Cloud Storage

AWS S3, GCS, ADLS



Processamento

Apache Spark,
Databricks



Formatos de Tabela

Delta Lake, Iceberg,
Hudi



Query & BI

Trino, Snowflake,
BigQuery

Trino & MinIO

A Infraestrutura de Dados Moderna e Escalável

| O que é o Trino?



Análise em Larga Escala

O Trino é um motor de consulta SQL distribuído projetado para consultar grandes conjuntos de dados distribuídos em uma ou mais fontes de dados heterogêneas.

Origem: Surgiu no Facebook em 2012 como Presto. Em 2020, foi renomeado para Trino sob a gestão da Trino Software Foundation.

Para que serve o Trino?



Performance

Consultas interativas rápidas em petabytes de dados, minimizando o tempo de espera para analistas de BI.



Federação

Permite unir dados de diferentes fontes (Hive, MySQL, Kafka, Cassandra) em uma única consulta SQL.



Desacoplamento

Separa o processamento do armazenamento, permitindo escalar a computação conforme a necessidade.

| Exemplo de Uso e BI

 **Consulta SQL:** Combine dados de vendas no MySQL com logs no HDFS em um único JOIN.

 **Conexão BI:** Conecta-se nativamente com ferramentas como Tableau, PowerBI e Apache Superset.

 **Eficiência:** Ideal para arquiteturas de Data Lakehouse e malha de dados (Data Mesh).

Recursos Oficiais

[Documentação](#)



O padrão ouro para armazenamento de objetos em nuvem híbrida

| O que é o MinIO?

Storage S3-Compatible

O MinIO é um servidor de armazenamento de objetos de alto desempenho, código aberto e totalmente compatível com a API do Amazon S3.

Ele foi projetado para lidar com dados não estruturados, como fotos, vídeos, arquivos de log e backups, sendo amplamente utilizado para construir infraestruturas de Cloud Storage privado ou híbrido.



| O que é o MinIO?

Storage S3-Compatible

Por ser extremamente leve e distribuído, ele é a escolha favorita para rodar em containers (Docker) e orquestradores como Kubernetes, permitindo que empresas tenham a mesma experiência de um bucket na nuvem dentro de seus próprios data centers.



| O que é o MinIO?

Storage S3-Compatible

Servidor de armazenamento de objetos de alto desempenho e código aberto, compatível com a API do Amazon S3.

Origem: Fundado em 2014, foi criado para lidar com o crescimento exponencial de dados não estruturados na era da nuvem.



| Documentação

Para mais informações

[Documentação MinIO](#) 



Obrigado!

Nome do Professor | [guilherme-lima-developer](#)



MBAUSP
ESALQ